

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ЛАБОРАТОРНАЯ РАБОТА №5
по дисциплине «Искусственные нейронные сети»
Тема: «Распознавание объектов на фотографиях»

Студент гр. 7383

Ханова Ю. А.

Преподаватель

Жукова Н. А.


Санкт-Петербург

2020

Цели.

Распознавание объектов на фотографиях (Object Recognition in Photographs)

CIFAR-10 (классификация небольших изображений по десяти классам: самолет, автомобиль, птица, кошка, олень, собака, лягушка, лошадь, корабль и грузовик).



Задачи.

- Ознакомиться со сверточными нейронными сетями
- Изучить построение модели в Keras в функциональном виде
- Изучить работу слоя разреживания (Dropout)
- Построить и обучить сверточную нейронную сеть
- Исследовать работу сеть без слоя Dropout
- Исследовать работу сети при разных размерах ядра свертки

Ход работы.

В качестве практической части построим глубокую сверточную нейронную сеть и применим ее к классификации изображений из набора CIFAR-10.

Зададим следующие гиперпараметры:

batch_size — количество обучающих образцов, обрабатываемых одновременно за одну итерацию алгоритма градиентного спуска;

num_epochs — количество итераций обучающего алгоритма по всему обучающему множеству;

kernel_size — размер ядра в сверточных слоях;

pool_size — размер подвыборки в слоях подвыборки;

conv_depth — количество ядер в сверточных слоях;

drop_prob (dropout probability) — мы будем применять dropout после каждого слоя подвыборки, а также после полносвязного слоя;

hidden_size — количество нейронов в полносвязном слое MLP.

Изначально зададим количество эпох равным 15 и размер ядра 3, слой Dropout включен. Полученный результаты представлены на рис.1-2.




Рисунок 1 — точность при размере ядра свертки 3×3 и включенном Dropout




Рисунок 2 – ошибка при размере ядра свертки 3×3 и включенном Dropout

Из графиков видно, что точность при данной модели сети составляет примерно 72%

Далее слой Dropout был отключен, а размер ядра оставим прежним, результаты представлены на рис.3-4.




Рисунок 3 – точность при размере ядра свертки 3×3 и выключенном Dropout




Рисунок 4 – ошибка при размере ядра свертки 3×3 и выключенном Dropout

Из графиков можно заметить, что точность увеличилась на тренировочный данных, однако на тестовых данных она понижается и становится примерно равной 69%. Здесь можно сделать вывод об оправданности использования слоя Dropout.

Далее исследуем работу сети при разных значениях размера ядра, результаты приведены на рис.5-8.




Рисунок 5 – точность при размере ядра свертки 7×7




Рисунок 6 – ошибка при размере ядра свертки 7×7




Рисунок 7 – точность при размере ядра свертки 5×5




Рисунок 8 – ошибка при размере ядра свертки 5×5

Из графиков видно, что при меньшем размере ядра и при равенстве других параметров сеть выдает большую точность – 80%, тогда как при большем значении – 76%

Вывод.

В ходе выполнения лабораторной работы было изучено представление и обработка графических данных, цветных изображений из базы данных CIFAR-10. Было изучено влияние слоя разреживания (Dropout) на результат обучения сети. Dropout увеличивает устойчивость сети к переобучению. Также было выявлено, что при изменении размера ядра свёртки необходимо корректировать параметры всей модели. Код программы представлен в приложении А.

Приложения

Приложение А

```
import matplotlib.pyplot as plt
from keras.datasets import cifar10
from keras.models import Model
from keras.layers import Input, Convolution2D, MaxPooling2D,
Dense, Dropout, Flatten
from keras.utils import np_utils
import numpy as np

batch_size = 256
num_epochs = 15
kernel_size = 7
pool_size = 2
conv_depth_1 = 32
conv_depth_2 = 64
drop_prob_1 = 0.25
drop_prob_2 = 0.5
hidden_size = 512

(X_train, y_train), (X_test, y_test) = cifar10.load_data()
num_train, depth, height, width = X_train.shape
num_test = X_test.shape[0]
num_classes = np.unique(y_train).shape[0]
X_train = X_train.astype('float32')
X_test = X_test.astype('float32')
X_train /= np.max(X_train)
X_test /= np.max(X_train)
Y_train = np_utils.to_categorical(y_train, num_classes)
Y_test = np_utils.to_categorical(y_test, num_classes)

def build_model(dropout=True):
    inp = Input(shape=(depth, height, width))
    conv_1 = Convolution2D(conv_depth_1, (kernel_size,
kernel_size), padding='same', activation='relu')(inp)
    conv_2 = Convolution2D(conv_depth_1, (kernel_size,
kernel_size), padding='same', activation='relu')(conv_1)
    pool_1 = MaxPooling2D(pool_size=(pool_size,
pool_size))(conv_2)
    if dropout:
        drop_1 = Dropout(drop_prob_1)(pool_1)
    else:
        drop_1 = pool_1
    conv_3 = Convolution2D(conv_depth_2, (kernel_size,
kernel_size), padding='same', activation='relu')(drop_1)
    conv_4 = Convolution2D(conv_depth_2, (kernel_size,
kernel_size), padding='same', activation='relu')(conv_3)
```



```

        pool_2 = MaxPooling2D(pool_size=(pool_size,
pool_size))(conv_4)
        if dropout:
            drop_2 = Dropout(drop_prob_1)(pool_2)
        else:
            drop_2 = pool_2
        flat = Flatten()(drop_2)
        hidden = Dense(hidden_size, activation='relu')(flat)
        drop_3 = Dropout(drop_prob_2)(hidden)
        out = Dense(num_classes, activation='softmax')(drop_3)
        model = Model(inp, out)
        model.compile(loss='categorical_crossentropy',
optimizer='adam', metrics=['accuracy'])
        history = model.fit(X_train, Y_train,
batch_size=batch_size, epochs=num_epochs, verbose=1,
validation_split=0.1)
        print(model.evaluate(X_test, Y_test, verbose=1))

        x = range(1, num_epochs + 1)
        plt.plot(x, history.history['loss'], label='Training loss')
        plt.plot(x, history.history['val_loss'], label='Validation
loss')
        plt.title('Training and validation loss')
        plt.xlabel('Epoch')
        plt.ylabel('Loss')
        plt.legend()
        plt.show()
        plt.clf()

        plt.plot(x, history.history['accuracy'], label='Training
accuracy')
        plt.plot(x, history.history['val_accuracy'],
label='Validation accuracy')
        plt.title('Training and validation accuracy')
        plt.ylabel('Accuracy')
        plt.xlabel('Epoch')
        plt.legend()
        plt.show()

build_model()

```